



UNIVERSIDADE ESTADUAL DE CAMPINAS

INSTITUTO DE COMPUTAÇÃO

MO443 - INTRODUÇÃO AO PROCESSAMENTO DE IMAGEM DIGITAL

PROF^o. DR^o. HÉLIO PEDRINI

Trabalho 2

Luís Antônio Almeida Lima Vieira
RA: 221045

1 Introdução

Este trabalho tem como objetivo principal, implementar e analisar métodos de segmentação de imagens e detecção de transições abruptas em vídeos. Os métodos de segmentação de imagens permitem destacar estruturas semânticas relevantes de objetos, para facilitar tarefas de interpretação e análise de imagens [1]. O princípio básico consiste em considerar *pixels* pertencentes a um objeto com valor preto (255) e *pixels* pertencentes ao fundo com valor branco (0), produzindo uma imagem binária. Já o processo de detecção de transições em vídeos, consiste em encontrar diferenças abruptas entre os quadros (imagens) que compõem o vídeo. Com isso, é permitido uma sumarização do conteúdo em menos quadros, ao considerar apenas os quadros pertencentes à momentos de transição. Para experimentar estas abordagens, foram utilizadas imagens e vídeos reais, seguida de uma análise dos resultados.

2 Materiais e Métodos

Para a realização dos experimentos, foram utilizadas imagens no formato PGM (*Portable GrayMap*), obtidas a partir da página http://www.ic.unicamp.br/~helio/imagens_pgm/ [2] e vídeos, obtidos na página http://www.ic.unicamp.br/~helio/videos_mp4/ [3]. Os enunciados da atividade estão disponíveis em <http://www.ic.unicamp.br/~helio/disciplinas/MO443/trabalho2.pdf> [4].

Para desenvolvimento dos códigos, foi utilizado o sistema operacional *Ubuntu 22.04* na versão *WSL (Windows Subsystem for Linux)*, e nele, foi criado um ambiente específico a partir do *Miniconda* versão 25.9.1 [5]. Foram instalados os seguintes pacotes, mostrados na Tabela 1.

Tabela 1: Pacotes utilizados no Trabalho 1.

Pacote	Versão
python	3.13.9
numpy [6]	2.4.3
matplotlib [7]	3.10.8
opencv [8]	4.12.0

Foi criado um diretório contendo uma pasta chamada *images* e outra chamada *videos*, onde foram salvos todos os arquivos de entrada utilizados. As saídas geradas pelos programas foram salvas em uma pasta *outputs*, com subpastas por metodologia, onde foram salvas todas as imagens (formato PNG) e vídeos produzidos (formato MP4). Além disso, neste diretório, foi criado um arquivo *utils.py*, contendo as funções principais de implementação dos métodos além de funções auxiliares, e notebooks *trabalho2_limiarizacao.ipynb* e *trabalho2_transicoes_videos.ipynb*, com as execuções das funções por item e apresentação dos resultados. Sempre que pertinente, foram utilizados comandos vetorizados em *Python*, permitindo um menor tempo de execução dos códigos.

Para organização e reuso de etapas comuns aos diferentes métodos, foram desenvolvidas em *utils.py*, uma classe referente a limiarização global, uma outra referente a limiarização local e uma última referente ao processamento de vídeos. Essas classes contêm os métodos necessários e são importadas nos *notebooks*, onde são executadas para as imagens de entrada e os resultados são salvos e mostrados na tela.

2.1 Métodos de Limiarização Global e Local

O objetivo desta etapa foi realizar experimentos com métodos de limiarização global e local em imagens monocromáticas. Os métodos de limiarização global consistem em determinar um único valor de limiar, utilizado para

todos os *pixels* da imagem, e transformar *pixels* maiores que este limiar como parte do objeto (preto) e o restante como parte do fundo (branco). Por outro lado, os métodos de limiarização adaptativa local, calculam um limiar para segmentar os *pixels* da imagem com base na informação contida em uma vizinhança local, o que leva em conta as variações que podem ocorrer em diferentes regiões da imagem. Assim como na limiarização global, também é obtida uma imagem binária (preto e branco), com um *pixel* classificado como objeto (preto) se possuir um valor mais alto que o limiar, e branco caso contrário [4]. Foram implementados e testados os seguintes métodos de limiarização:

- **Método Global:** Se o valor de intensidade de um *pixel* (x, y) for maior do que um limiar T (por exemplo, $T = 128$), o *pixel* será considerado como pertencente ao objeto; caso contrário, será considerado como fundo;
- **Método de Otsu [9]:** calcula automaticamente um limiar ótimo T para dividir a imagem em duas classes de *pixels* por meio da minimização da variância intraclasse. Sendo σ_B^2 a variância entre as classes do objeto, σ_T^2 a variância total, μ_0 a média da classe de fundo, μ_1 a média da classe do objeto e μ_T a média total:

$$\eta(T) = \frac{\sigma_B^2}{\sigma_T^2} \quad (1)$$

$$T = \operatorname{argmax}(\eta(T)) \quad (2)$$

$$\sigma_T^2 = \sum_{i=0}^{L-1} (i - \mu_T)^2 p_i, \quad \mu_T = \sum_{i=0}^{L-1} i p_i, \quad \sigma_B^2 = \omega_0 \omega_1 (\mu_0 - \mu_1)^2, \quad \omega_0 = \sum_{i=0}^T p_i, \quad \omega_0 = 1 - \omega_1, \quad \mu_0 = \frac{\mu_S}{\omega_0},$$

$$\mu_1 = \frac{\mu_T - \mu_S}{\omega_1}, \quad \mu_S = \sum_{i=0}^T i p_i, \quad \sum_{i=0}^{L-1} p_i = 1, \quad p_i = \frac{n_i}{n}$$

Temos que

$$\begin{aligned} \sigma_B^2 &= \omega_0 \omega_1 \left(\frac{\mu_S}{\omega_0} - \frac{\mu_T - \mu_S}{\omega_1} \right)^2 \\ \sigma_B^2 &= \omega_0 \omega_1 \left(\frac{\mu_S \omega_1 - \omega_0 (\mu_T - \mu_S)}{\omega_0 \omega_1} \right)^2 \\ \sigma_B^2 &= \omega_0 \omega_1 \left(\frac{\mu_S (\omega_0 + \omega_1) - \omega_0 \mu_T}{\omega_0 \omega_1} \right)^2 \end{aligned}$$

Como $\omega_0 + \omega_1 = 1$:

$$\sigma_B^2 = \frac{(\mu_S - \omega_0 \mu_T)^2}{\omega_0 \omega_1}$$

Como $\omega_1 = 1 - \omega_0$:

$$\sigma_B^2 = \frac{(\mu_S - \omega_0 \mu_T)^2}{\omega_0 (1 - \omega_0)}$$

$$T(x, y) = \operatorname{argmax} \left(\frac{(\mu_S - \omega_0 \mu_T)^2}{\omega_0 (1 - \omega_0)} \right) \quad (3)$$

Sendo μ_S e ω_0 a média e a soma de probabilidade acumulada até o T testado e μ_S a média total.

- **Método de Bernsen [10]:** Para cada pixel (x,y) , o limiar é calculado como:

$$T(x, y) = (z_{min} + z_{max})/2 \quad (4)$$

em que z_{min} e z_{max} são os valores de níveis de cinza mínimo e máximo, respectivamente, em uma vizinhança $n \times n$ centrada em (x,y) ;

- **Método de Niblack [11]:** O valor de limiar é baseado na média local e no desvio padrão. O valor de limiar em um *pixel* (x,y) é calculado como

$$T(x, y) = \mu(x, y) + k\sigma(x, y) \quad (5)$$

em que $\mu(x, y)$ e $\sigma(x, y)$ são a média e o desvio padrão, respectivamente, em uma vizinhança local de (x,y) . O tamanho da vizinhança deve ser suficientemente pequeno para preservar detalhes locais, mas, ao mesmo tempo, suficientemente grande para suprimir ruído. O valor de k é usado para ajustar a fração da borda do objeto a ser considerada como parte do objeto. Segundo Trier e Jain (1995) [12], um tamanho de janela de 15 e $k = -0.2$ geram bons resultados no geral;

- **Método de Sauvola e Pietaksinen [13]:** Procura melhorar os resultados do método de *Niblack*, particularmente para imagens de documentos apresentando má iluminação. O limiar se adapta de acordo com a média local e o desvio padrão sobre uma janela de tamanho $n \times n$ *pixels*. O limiar em um *pixel* (x,y) é calculado como

$$T(x, y) = \mu(x, y) \left[1 + k \left(\frac{\sigma(x, y)}{R} - 1 \right) \right] \quad (6)$$

em que $\mu(x, y)$ e $\sigma(x, y)$ são definidos como em [11]. *Sauvola e Pietaksinen* sugerem valores de $k = 0.5$ e $R = 128$;

- **Método de Phansalskar, More e Sabale [14]:** Variação do método [13] para lidar com imagens de baixo contraste. O limiar é calculado como

$$T = \mu(x, y) \left[1 + p \exp(-q\mu(x, y)) + k \left(\frac{\sigma(x, y)}{R} - 1 \right) \right] \quad (7)$$

em que $\mu(x, y)$ e $\sigma(x, y)$ são a média e o desvio padrão, respectivamente, em uma vizinhança local de (x,y) . Os autores sugerem $k = 0.25$, $R = 0.5$, $p = 2$ e $q = 10$. Qualquer outro valor numérico diferente de 0 é válido para k . O valor de R é diferente do método [13], pois usa uma intensidade normalizada da imagem;

- **Método do Contraste:** Atribui o valor de um pixel como fundo ou objeto, dependendo se seu valor está mais próximo do máximo ou mínimo local, respectivamente;
- **Método da Média:** Seleciona o limiar como a média da distribuição local de intensidade calculada no interior de uma vizinhança. A média é então subtraída de um valor constante. O limiar é calculado como

$$T = \mu(x, y) - C \quad (8)$$

em que $\mu(x, y)$ é a média em uma vizinhança local de (x,y) e C é uma constante de ajuste do limiar. Dessa forma, se o valor de um pixel (x,y) for maior do que o limiar T , o pixel será considerado como pertencente ao objeto; caso contrário, será considerado como fundo;

- **Método da Mediana:** Seleciona o limiar como a mediana da distribuição local de intensidade. Dessa forma, se o valor de um pixel (x,y) for maior do que a mediana de sua vizinhança, o pixel será considerado como pertencente ao objeto; caso contrário, será considerado como fundo.

Com relação aos métodos que necessitam de uma escolha de parâmetros, foram realizados testes com variações aleatórias para além da sugestão dos autores. Para avaliar a qualidade, uma inspeção visual foi realizada.

2.2 Detecção de Transições em Vídeos

Segundo [4], um vídeo digital pode ser definido como uma coleção de imagens de mesmas dimensões, sendo agrupadas de acordo com uma sequência temporal (Figura 1). Cada uma dessas imagens é denominada quadro, o qual corresponde à menor unidade estrutural do vídeo. Os quadros podem ser agrupados em tomadas, que são sequências de quadros capturados de forma contígua e que representam uma ação contínua no tempo ou no espaço. Finalmente, um grupo de tomadas que são semanticamente correlacionadas constitui uma cena.




Figura 1: Estrutura geral de um vídeo

Nesse trabalho, o objetivo foi detectar transições abruptas que ocorrem entre quadros que compõem um vídeo após convertido para escala de cinza.

Há diferentes tipos de transições em vídeos. Um corte (*cut*) é uma mudança abrupta que ocorre em um único quadro. Um desbotamento (*fade*) corresponde à mudança lenta em brilho, normalmente resultando em um quadro totalmente preto. Uma dissolução (*dissolve*) ocorre quando um quadro gradualmente desaparece, enquanto seu quadro consecutivo torna-se mais visível. Uma limpeza (*wipe*) ocorre quando *pixels* de um quadro são trocados com *pixels* do quadro adjacente conforme um padrão regular, por exemplo, uma coluna a partir da borda esquerda dos quadros [4]. Foram implementados e testados os seguintes métodos:

- **Diferenças entre Pixels:** Dois quadros consecutivos são considerados significativamente diferentes se a contagem do número de *pixels* que sofrem alteração em intensidade, conforme uma certa tolerância T_1 , é maior que um segundo limiar T_2 ;
- **Diferenças entre Blocos:** dois quadros consecutivos são divididos em 8×8 ou 16×16 blocos sem sobreposição. O erro quadrático da diferença de dois blocos correspondentes entre as imagens deve ser calculado e testado contra um limiar T_1 . Se o erro for menor do que o limiar, então os quadros são considerados similares; caso contrário, eles são considerados distintos. Um segundo limiar T_2 deve ser definido e utilizado para avaliar o número de blocos que possuem erro quadrático maior do que T_1 . Se esse número exceder T_2 , então o quadro será considerado uma transição abrupta.
- **Diferenças entre Histograma:** A diferença D_i dos histogramas de intensidades para dois quadros consecutivos i e $i + 1$ do vídeo pode ser expressa como

$$D_i = \sum_{j=1}^L |H_i(j) - H_{i+1}(j)| \quad (9)$$

em que B denota o número total de *bins* no histograma e $Hi(j)$ é o valor do histograma para o i -ésimo quadro no nível j . Um limiar T deve ser utilizado para determinar se a diferença dos histogramas de intensidade D_i indica uma transição abrupta no vídeo. O limiar pode ser estimado como

$$T = \mu + \alpha\sigma \quad (10)$$

em que μ e σ são, respectivamente, o valor médio e o desvio padrão da diferença dos histogramas de intensidade. O valor de α tipicamente varia de 3 a 6.

3 Resultados e Discussão

3.1 Métodos de Limiarização Global e Local

3.1.1 Método Global

Para este método, foi desenvolvida uma função simples vetorizada (*global_limiarization*), dentro da classe de limiarização global (*GlobalLimiarization*), que recebe uma imagem monocromática e um limiar e mapeia *pixels* maiores que o limiar para o valor 0 (preto) e menores para o valor 255. Foi testado os valores de limiar: 128 (metade do histograma), 40 e 170. Como mostra as Figura 2 abaixo, limiares mais baixos deixam as imagens mais escuras (maior classificação de objetos) e limiares mais altos deixam as imagens mais claras.



Figura 2: Resultado da aplicação de diferentes limiares nas imagens de entrada.

Outro ponto interessante a ser notado na Figura 2 são inconstâncias entre diferentes regiões das imagens, causada, por exemplo por luz e sombra, o que compromete o resultado da limiarização global em alguns casos com perda de informação. Para o limiar $T = 128$, foram comparados os histogramas das imagens antes e após a transformação (Figuras 3 e 4). A Figura 5 mostra casos em que o histograma global é relativamente separável em 2 grupos, o que torna um resultado mais separável de segmentação.




Figura 3: Histogramas para $T = 128$.




Figura 4: Histogramas para $T = 128$.




Figura 5: Histogramas para T=40 e T=160.

3.1.2 Método de Otsu

Para o método de *Otsu*, foi desenvolvida uma função dentro da classe de limiares globais, em que o limiar é calculado como a posição de 0 a 255 que maximiza a variância entre fundo e objeto, conforme a Equação 3. Foi obtido o histograma normalizado (pela função *calculate_grayscale_histogram*), e a partir dele, vetores de soma e média acumulada, representando estes valores para cada posição de 0 a 255. A média total foi obtida como a média acumulada da última posição do histograma. Com esses valores, para cada T (0 a 255) foi calculada a variância entre as classes (Equação 3). O ponto de variância máxima é o valor de T escolhido. Com isso, *pixels* maiores que T, apresentam valor preto (objeto). Foram obtidas as imagens da Figura 6 e os histogramas das Figuras 7 e 8.



Figura 6: Resultados do método de Otsu.




Figura 7: Histogramas do método de Otsu.




Figura 8: Histogramas do método de Otsu.

Observa-se nas imagens que apresenta um resultado similar ao método global para a maioria dos casos, com a vantagem de que não é necessário escolher parâmetros de entrada, com a própria função encontrando o melhor limiar global possível. Assim como no método global, efeitos de luz sombra afetam bastante os resultados.

3.1.3 Método de Bernsen

Para este método, foi desenvolvida uma função dentro da classe de limiares locais (*LocalLimiarization*). Esta classe, ao ser inicializada, divide a imagem em janelas, com tamanho definido (dimensões da vizinhança). O limiar de cada *pixel* é definido por operações nos valores internos de sua janela de vizinhança. Para o método de *Bernsen*, foi utilizada a equação 4 para obtenção dos limiares, e como nos outros casos, valores maiores que o limiar, assumem o tom preto. Foi aplicado o método e feita uma variação no tamanho da janela de vizinhança (Figura 9), testando os valores 5, 15, 41. Janelas muito pequenas tendem a deixar as imagens resultantes mais granuladas, pois levam em conta um contexto muito pequeno. Janelas maiores tendem a produzir zonas quadradas constantes




Figura 9: Método de Bernsen para diferentes tamanhos de janela.




Figura 10: Histogramas do método de Bernsen com janela de 15.




Figura 11: Histogramas do método de Bersen com janela 15.

É possível perceber que no caso de limiarização local, menos detalhes são perdidos com relação à limiarização global, além de se mostrar menos sensível a luz e sombra, apesar de ainda ser visto os efeitos causados por variação de iluminação. Além disso, percebe-se um aumento na taxa de *pixels* pretos.

3.1.4 Método de Niblack

Este, também foi desenvolvido como um método da classe de limiarização local, semelhante ao de *Bernsen*, alterando apenas a função de cálculo do limiar (Equação 5). Para este caso, foi mantida a janela de tamanho 15 e o valor de k foi variado entre -0.2 (recomendado Trier e Jain (1995) [12]), 0.2 e 0.7. Foram obtidos os resultados da Figura 12 e os histogramas das Figuras 13 e 14.



Figura 12: Método de Niblack para janela 15 e diferentes valores de k.




Figura 13: Histogramas do método de Niblack para janela 15 e k -0.2.




Figura 14: Histogramas do método de Niblack para janela 15 e $k = -0.2$.

No método de *Niblack*, quanto maior o valor de k , mais influência do desvio padrão local e menos *pixels* são classificados como objeto, por isso na Figura 12, para $k = 0.7$ há menos *pixels* pretos. Valores menores de k realçam as diferenças, mas se forem muito pequenos a tendência é uma classificação de tudo como objeto. Comparando com o *Bernsen*, percebe-se uma menor influência de luz e sombra e uma separação mais clara entre fundo e objeto para todas as imagens, apesar de ainda parecer um pouco ruidoso.

3.1.5 Método de Sauvola e Pietaksinen

Este método segue o mesmo princípio dos métodos de limiarização local anteriores, alterando a função de definição do limiar local, agora pela Equação 6. Neste caso, além do termo k , há outro parâmetro R . O termo k controla o efeito de sensibilidade ao contraste, para valores altos, há maior realce, porém a imagem pode ser contaminada por ruído. Já o R controla a intensidade do desvio padrão diretamente, sendo que para valores altos o limiar fica menos dependente de contraste [13]. Foram testados diferentes combinações de k e R . Além da combinação sugerida pelos autores, com $k = 0.5$ e $R = 128$. Os resultados estão mostrados na Figura 15.



Figura 15: Método de Sauvola para janela 15 $k = 0.5$ variando R .

Método de Sauvola e Pietaksinen window 15 k 0.15 R 128




Figura 16: Resultados do método de Sauvola para janela 15, R 128 e k 0.15.




Figura 17: Histogramas do método de Sauvola para janela 15 e k 0.15, R 128.




Figura 18: Histogramas do método de Sauvola para janela 15 e k 0.15, R 128.

As figuras mostram uma boa separação entre fundo e objeto. Percebeu-se que para valores altos de k e R , o número de *pixels* pretos aumenta consideravelmente, em alguns casos, resultando em uma segmentação falha com todos os valores 0. É possível concluir que esta nova formulação de limiar deixa mais sutis as delimitações dos objetos, inclusive possibilitando a leitura do texto na imagem central da Figura 18. Percebe-se que, assim como os autores sugerem, há uma melhora para tratar luz e sombra e é ideal para documentos.

3.1.6 Método de Phansalskar, More e Sabale

Este método é um complemento do método de Sauvola, em que muda a função de cálculo do limiar, adicionando agora com novos parâmetros p e q , segundo a Equação 7, além dos mesmos parâmetros k e R discutidos no tópico anterior. O parâmetro p pondera um termo exponencial com a taxa de decaimento definida por q . Este termo melhora a correção de regiões mais escuras da imagem. Utilizando os valores. Importante notar, que a fórmula da equação 7 pede uma imagem normalizada, isto é, todos os valores divididos pelo máximo. As Figuras 19 a 21 mostram os resultados obtidos. Neste caso, percebeu-se uma melhora na nitidez e contraste dos objetos, com relação aos casos anteriores. Assim como no método de *Sauvola*, há melhora para segmentação de documentos, apresentando melhor nitidez, devido aos termos adicionados pelos autores nas equações.



Figura 19: Método de Phansalskar para janela 15 e diferentes valores de k , R 0.5, p 2 e q 10.




Figura 20: Histogramas do método de Phansalskar para janela 15 e diferentes valores de k, R 0.5, p 2 e q 10.




Figura 21: Histogramas do método de Phansalskar para janela 15 e diferentes valores de k, R 0.5, p 2 e q 10.

3.2 Método de Contraste

Este método também foi criado dentro da classe de limiarização local. Neste caso, atribui o valor do *pixel* como fundo se está mais próximo do máximo local e objeto, se está mais próximo do mínimo local. É possível ver uma boa separação entre fundos e objetos, apesar da presença de um certo ruído. Neste método as bordas de separação ficam bem evidentes, devido ao realce de contraste. Assim como os últimos métodos apresentados, este também é robusto à luz e sombra, porém ruídos do fundo são realçados também. A grande vantagem é a não necessidade de definição de parâmetros.




Figura 22: Método de Contraste para diferentes janelas.




Figura 23: Histogramas do método de Contraste para janela 15.




Figura 24: Histogramas do método de Contraste para janela 15.

3.3 Método de Média

Neste método, foi desenvolvido, dentro da classe de limiarização local, o cálculo do limiar pela média dos vizinhos subtraída por uma constante C (Equação 8). É possível perceber que para valores muito altos de C , o limiar tende a ser baixo, resultando em imagens totalmente pretas. Para $C = 10$, visualmente, os resultados parecem bem separáveis. Este método se assemelha ao de *Sauvola*, com a vantagem de ser mais simples e possuir apenas um parâmetro a ser definido. No mais, se mostrou robusto à variações de luz, sombra e ruído, com uma resposta limpa.




Figura 25: Método de Média para diferentes constantes.




Figura 26: Histogramas do método de Média para C 10.




Figura 27: Histogramas do método de Média para C 10.

3.4 Método de Mediana

Neste método, similar ao método da média, é calculada a mediana da vizinhança, neste caso sem nenhuma constante de ajuste. Este método se mostrou mais promissor para janelas maiores, muito provavelmente pois neste caso mais informações da vizinhança são utilizadas para o cálculo do limiar e não resultou em um aumento de ruído pois a mediana é por natureza robusta à valores que fogem do padrão da vizinhança. Neste caso, pela natureza da fórmula da mediana, o método se torna robusto à ruído impulsivo. Além de não necessitar de parametrização, o método respondeu bem às imagens testadas. Uma característica apresentada foi a maior segmentação de detalhes das imagens, o que pode ser problemático dependendo da aplicação.



Figura 28: Método de Mediana para diferentes janelas.




Figura 29: Histogramas do método de Mediana.




Figura 30: Histogramas do método de Mediana.

3.5 Detecção de Transição em Vídeos

Para o desenvolvimento da solução, foi desenvolvida uma classe (*Videos*) com métodos úteis para processar as transições dos vídeos de entrada, incluindo os métodos de detecção de transições por diferença entre *pixels*, diferença entre blocos e diferença entre histogramas de quadros consecutivos. Métodos auxiliares para salvamento e demonstração também foram desenvolvidos dentro desta classe.

3.5.1 Diferença entre Pixels

Este método consiste em converter o vídeo para escala de cinza, percorrer os quadros e calcular a diferença de intensidade *pixel a pixel*. A diferença mínima necessária para considerar uma alteração é definida por um limiar T1 (parâmetro da função) e o número de *pixels* que sofrem alteração (diferenças maiores que o limiar T1) é comparado com um segundo limiar T2. Se maior que T2, é considerada uma alteração abrupta entre quadros. Portanto, para o teste de funcionamento, foram feitas algumas variações de T2, acompanhando um gráfico da evolução da métrica de medida (soma dos *pixels que diferem*). As Figuras 31 e 32 a 34 mostram alguns resultados da aplicação deste método. A escolha dos limiares foi empírica, com base na visualização do gráfico que mostrados na Figura 33, que representam o número de *pixels* que possuíram diferença maior que T2 entre quadros. Ao variar o valor de T1 (Figura 33), percebe-se que valores pequenos deixam a detecção muito sensível, e valores grandes causam perdas de transições. T2 pode ser escolhido pelo gráfico.




Figura 31: Método da diferença entre Pixels. A medida é referente ao número de pixels com diferença significativa entre quadros. Valores acima do limiar no gráfico representam transições




Figura 32: Método da diferença entre Pixels. A medida é referente ao número de pixels com diferença significativa entre quadros. Valores acima do limiar no gráfico representam transições.




Figura 33: Método da diferença entre Pixels. Variação no parâmetro T1.

Caso para vídeos mais longos com muitas transições (torna a tarefa mais complicada).




Figura 34: Método da diferença entre Pixels. A medida é referente ao número de pixels com diferença significativa entre quadros. Valores acima do limiar no gráfico representam transições.

3.5.2 Diferença entre Blocos

O método da diferença entre blocos é semelhante à diferença entre *pixels*, porém a métrica é calculada de maneira diferente. Neste caso, cada quadro é dividido em 8x8 blocos ou 16x16. Após isso, o erro quadrático médio dos blocos entre quadros consecutivos é calculado. Se caso o erro resultar em um valor maior que o limiar T1, definido como parâmetro, o bloco é considerado de transição. Caso um número maior que o limiar T2 de blocos for caracterizado como transição, então o quadro é classificado como de transição. As Figuras 35 a 38 mostram o resultado da aplicação deste método. Para a escolha dos limiares, foi feita uma variação do valor de T1 e número de blocos e avaliada a evolução das medidas (Figuras 35 a 39). Assim como no caso da diferença de *pixels*, valores menores de T1 deixam a detecção mais sensível. Valores de T2 são escolhidos pelo gráfico mostrados nas Figuras abaixo. Para a divisão em blocos da imagem presente no quadro, foi utilizada uma operação vetorizada utilizando a operação *reshape* do *numpy*.




Figura 35: Método da diferença entre Blocos. A medida é referente ao erro quadrático médio entre os blocos que formam cada quadro. Valores acima do limiar no gráfico representam transições.




Figura 36: Método da diferença entre Blocos. A medida é referente ao erro quadrático médio entre os blocos que formam cada quadro. Valores acima do limiar no gráfico representam transições.




Figura 37: Método da diferença entre Blocos.Variação no parâmetro T1.




Figura 38: Método da diferença entre Blocos.Variação no número de blocos.




Figura 39: Método da diferença entre Blocos. A medida é referente ao erro quadrático médio entre os blocos que formam cada quadro. Valores acima do limiar no gráfico representam transições.

3.5.3 Diferença entre Histogramas

Por fim, o método da diferença entre histogramas é definido pela Equação 9. O histograma de cada quadro é calculado, e a métrica é obtida pela soma da diferença entre os valores dos histogramas. O limiar neste caso, é definido pela Equação 10, em que leva-se em conta a média e o desvio padrão das métricas de diferença de histograma em todo o vídeo. Por este motivo, neste método é necessário percorrer o vídeo duas vezes. Com isso, posições que possuem diferenças de histograma maiores que o valor do limiar, são consideradas como transições. As imagens abaixo mostram resultados da aplicação deste método. O parâmetro α também foi variado empiricamente (Figuras 40 a 43), com base nos gráficos.




Figura 40: Método da diferença entre Histogramas. A medida é referente ao erro entre os histogramas de cada quadro. Valores acima do limiar no gráfico representam transições.




Figura 41: Método da diferença entre Histogramas. A medida é referente ao erro entre os histogramas de cada quadro. Valores acima do limiar no gráfico representam transições.




Figura 42: Método da diferença entre Histogramas. Variação no parâmetro alpha.




Figura 43: Método da diferença entre Histogramas. A medida é referente ao erro quadrático médio entre os blocos que formam cada quadro. Valores acima do limiar no gráfico representam transições.

É possível perceber uma vantagem neste método por ser suficiente a escolha de um só parâmetro. Apesar deste fato, o método de histograma é mais ineficiente computacionalmente por precisar percorrer mais de uma vez o vídeo, que pode ser de longa duração. Além disso este método não é tão preciso para a escolha de limiares.

4 Conclusões

Este trabalho permitiu um aprofundamento em tópicos de segmentação (limiarização) de imagens. Como pôde ser notado, quanto mais complexas se apresentarem as imagens de interesse, uma maior dificuldade ocorre para separar o *pixels* que representam um objeto e os que representam o fundo. Foram abordados diferentes métodos em uma ordem crescente de complexidade e capacidade de segmentação. Os métodos de segmentação global apresentam um bom funcionamento para imagens simples em que os histogramas se mostram em grupos bem separáveis. Nesses casos, um simples limiar de intensidade é capaz de destacar as posições referentes à objetos. Porém, considerando a complexidade e a presença de ruídos e variações de iluminação, métodos mais robustos são necessários. Os métodos de limiarização local, tendem a ajustar melhor estes problemas por levar em conta características locais ao definir os limiares. Percebeu-se que alguns métodos possuem resultados próximos, como por exemplo *Sauvola* [11] e o método da média.

Uma dificuldade encontrada se relaciona com um ponto negativo de alguns métodos, referente à parametrização. Os valores escolhidos foram empíricos, apenas com a análise visual dos resultados. Além disso, nem sempre estes parâmetros generalizam bem para diferentes tipos de imagens. Com isso, métodos de parametrização automática poderiam ser empregados, por meio de resolução de problemas de otimização. Métodos de média, contraste e mediana encontraram resultados satisfatórios, com pouco ou sem necessidade de parametrização.

Com relação à identificação de transições em vídeos, foram abordados 3 métodos. Algumas dificuldades foram encontradas com o tempo de processamento, para casos de vídeos mais longos. Otimizações foram feitas no código para melhorar o tempo computacional e uso de memória, que inicialmente ocasionaram problemas. Para testar o funcionamento, foram priorizados vídeos mais curtos. Assim como no caso da limiarização, o processo de escolha empírica dos parâmetros se apresenta como uma dificuldade, e os valores escolhidos variam bastante para diferentes vídeos. No mais, foi possível constatar o funcionamento. Vale ressaltar que neste trabalho, priorizou-se o uso de funções customizadas, de maneira a fixar melhor os conteúdos. Quando funções prontas foram encontradas, no *OpenCV*, os resultados foram comparados.

Referências

- [1] Hélio Pedrini. Segmentação. http://www.ic.unicamp.br/~helio/disciplinas/M0443/aula_segmentacao.pdf, 2026. Acesso em: 28 mar. 2026.
- [2] Hélio Pedrini. Banco de imagens pgm. http://www.ic.unicamp.br/~helio/imagens_pgm/, 2025. Acesso em: 23 abr. 2026.
- [3] Hélio Pedrini. Banco de vídeos mp4. http://www.ic.unicamp.br/~helio/videos_mp4/, 2025. Acesso em: 23 abr. 2026.
- [4] Hélio Pedrini. Trabalho2. <http://www.ic.unicamp.br/~helio/disciplinas/M0443/trabalho2.pdf>, 2026. Acesso em: 23 abr. 2026.
- [5] Anaconda, Inc. Miniconda release notes (version 25.9.1-1). <https://www.anaconda.com/docs/getting-started/miniconda/release-notes#miniconda-25-9-1-1>, 2025. Acesso em: 04 abr. 2026.
- [6] NumPy Developers. Numpy documentation. <https://numpy.org/doc/2.4/reference/index.html>, 2025. Acesso em: 04 abr. 2026.
- [7] Hunter, et al. Opencv documentation. <https://matplotlib.org/stable/index.html>, 2025. Acesso em: 04 abr. 2026.
- [8] OpenCV. Opencv documentation. <https://docs.opencv.org/4.12.0/>, 2025. Acesso em: 04 abr. 2026.
- [9] Nobuyuki Otsu et al. A threshold selection method from gray-level histograms. *Automatica*, 11(285-296), 1979.
- [10] J. Bernsen. Dynamic thresholding of grey-level images. In *Proceedings of the 8th International Conference on Pattern Recognition (ICPR)*, pages 1251–1255, Paris, France, 1986.
- [11] W. Niblack. *An Introduction to Digital Image Processing*. Strandberg, 1985. ISBN 9788787200554. URL <https://books.google.com.br/books?id=Lcg8PgAACAAJ>.
- [12] Oeivind Due Trier and Anil K. Jain. Goal-directed evaluation of binarization methods. *IEEE transactions on Pattern analysis and Machine Intelligence*, 17(12):1191–1201, 1995.

- [13] Jaakko Sauvola and Matti Pietikäinen. Adaptive document image binarization. *Pattern Recognition*, 33(2):225–236, 2000. doi: 10.1016/S0031-3203(99)00055-2.
- [14] Neerad Phansalkar, Sumit More, Ashish Sabale, and Madhuri Joshi. Adaptive local thresholding for detection of nuclei in diversity stained cytology images. In *2011 International Conference on Communications and Signal Processing (ICCSP)*, pages 218–220. IEEE, 2011.